

ICLR

算法流程

1.2 用一个 5×5 例子贯穿（演示流程；数值只示意）

设定：

- 当前位置与时刻：(x_t, t)。从网络得到 **score**： $g_t = s_\theta(x_t, t) \in \mathbb{R}^5$ （例如 $g = [1.2, -0.5, 0.8, 0.1, 0.0]^T$ ）。
- 给一个**非对称**的近似 Hessian 数值算子 H（仅用于演示出对称化；实现里不显式存矩阵，只要能算 JVP/VJP 即可）：

nginx

 复制代码

H (5×5, 非对称, 仅示意)

```
[ 4,  1,  0,  0,  0
  0,  2,  3,  0,  0
  0,  0,  1,  2,  0
  0,  0,  0,  0.2, 0
  1,  0,  0,  0,  0.1 ]
```

通过算子法构造 $*H_{sym} \cdot v = 0.5(JVP(v) + VJP(v))^{**}$ ，等价于矩阵层面 $H_{sym} = (H + H^T)/2$ （此处仅为帮助理解）。

 HILDA_ICLR0

$$H_{\text{sym}}(x, t) = \frac{1}{2}(H(x, t) + H(x, t)^T)$$

The symmetrized Hessian-vector product can be implemented efficiently without explicit matrix formation. For a vector $v \in \mathbb{R}^d$, we define the Jacobian-vector product $\text{JVP}(s_\theta(\cdot, t), v) = J_{s_\theta}(x, t)v$ and the vector-Jacobian product $\text{VJP}(s_\theta(\cdot, t), v) = J_{s_\theta}(x, t)^T v$, then compute:

$$H_{\text{sym}}v = \frac{1}{2}(\text{JVP}(s_\theta, v) + \text{VJP}(s_\theta, v)) \quad (8)$$

Step A — 对称化（必做）

计算 Hsym（略去逐项相加），得到一个对称的 5×5（演示）：

nginx

 复制代码

Hsym ≈

```
[ 4.0, 0.5, 0.0, 0.0, 0.5
  0.5, 2.0, 1.5, 0.0, 0.0
  0.0, 1.5, 1.0, 1.0, 0.0
  0.0, 0.0, 1.0, 0.2, 0.0
  0.5, 0.0, 0.0, 0.0, 0.1 ]
```

Step B — Lanczos ($m=4$) 估计极值特征值

- 初始化 v_1 为单位随机向量; 循环 4 步, 得到三对角 T_k ; 求 $\text{eig}(T_k)$ 近似 $\hat{\alpha}_t \approx \lambda_{\max}(H_{\text{sym}})$ 、 $\hat{\beta}_t \approx \lambda_{\min}(H_{\text{sym}})$ 。
- 这里 $\hat{\alpha}_t, \hat{\beta}_t$ 来源于数据/自动微分+向量乘 (需要从实际模型计算得到)。
例: 假设 Lanczos 给出 $\hat{\alpha}_t \approx 4.6, \hat{\beta}_t \approx 0.08$ (演示值)。

Step C — 计算阻尼 λ_t 与归一化 c_t

- 设 $\kappa^* = 75$ (默认范围 50–100, 与论文 Lemma 1/3 的收敛上界匹配)。
- $\lambda_t = \max(0, (\hat{\alpha}_t - \kappa^* \hat{\beta}_t) / (\kappa^* - 1))$
 $= \max(0, (4.6 - 75 \times 0.08) / 74) = \max(0, (4.6 - 6.0) / 74) = \max(0, -1.4 / 74) = 0$
→ 当前条件数已可接受, 无需阻尼。
- $c_t = \hat{\beta}_t + \lambda_t = 0.08 + 0 = 0.08$
- 定义 SPD 线性算子: $A_t(v) = H_{\text{sym}} \cdot v + \lambda_t v = H_{\text{sym}} \cdot v$ (此刻 $\lambda_t = 0$)。

若 $\hat{\beta}_t$ 较小或负 (近奇异/鞍点), λ_t 会自动抬升保证 $A_t > 0$ 且 $\kappa(A_t) \leq \kappa^*$; 此时 $c_t = \hat{\beta}_t + \lambda_t$ 仍确保 $\text{spec}(M_t) \subset [1/\kappa^*, 1]$ 。

Warm-start(用上一步的解, 不用每次都0初始化)

终止条件要和 k^* 设置保持一致, 观察 k 是否在相应次数收敛

Step D — 用 CG 解线性方程 $A_t d = g$ (warm-start)

(只要这个终止条件 τ 以及 κ^* 在之前就选定了, 那么这个迭代上界就确定了) 证明在下一页

- 初值 $d^{(0)}$ =上一步解 (首次可用0向量)。
- 迭代: $r^{(k)}=g-A_t d^{(k)}$; $p^{(k)}$ 为 A_t -共轭方向;
 $\alpha_k=(r^{(k)T} r^{(k)})/(p^{(k)T} A_t p^{(k)})$; $d^{(k+1)}=d^{(k)}+\alpha_k p^{(k)}$; ... (标准 CG)。
- 终止: $\|r^{(k)}\|/\|r^{(0)}\| \leq \tau$ (如 $1e-2$)。由于 $\kappa(A_t) \leq \kappa^*$, 理论上
迭代上界: $k \geq 0.5\sqrt{\kappa^*} \log(2/\tau)$ (Lemma 3)。以 $\kappa^*=75$, $\tau=1e-2$, $k \approx 3-4$ 。

HILDA_ICLR0

Step E — 得到几何校正分数并步进

- 输出 d_t ; 几何校正分数 $\hat{s}_t = c_t d_t = 0.08 \cdot d_t$ 。
- ODE 情况: 用 $\hat{s}_t$ 替换 $\nabla \log p_t$, 走 IntegratorStep (保持原有时间步长/阶数)。
- SDE 情况 (“冻结- M_t ”): 扩散项用 $g_t \sqrt{(2M_t)}$, 此时 $M_t = c_t A_t^{-1}$, 可用 $R^T R = M_t$ 的乘子实现
(实际中通常走概率流 ODE 路径, 或不显式抽样扩散增量)。

HILDA_ICLR0

备注: 实际实现不需要显式的 5×5 矩阵, 只要给定 v 能算出 $H_{\text{sym}} \cdot v$ 、 $A_t \cdot v$ 即可 (JVP/VJP)。上面的数值仅演示流程中每个量的来源与去向。

HILDA_ICLR0

这里的逻辑是 数值代数里 CG 收敛速率的经典结论：

- CG 的收敛误差界（针对 SPD 系统 $A_t d = g_t$ ）满足：

$$\frac{\|r^{(k)}\|}{\|r^{(0)}\|} \leq 2 \left(\frac{\sqrt{\kappa(A_t)} - 1}{\sqrt{\kappa(A_t)} + 1} \right)^k,$$

其中 $\kappa(A_t)$ 是条件数。

- 如果在 **Lanczos** 阶段我们人为地保证了 $\kappa(A_t) \leq \kappa_*$ （通过加阻尼 λ_t ），那么 CG 的收敛速率就被“锁死”在 κ_* 的范围里。
- 一旦容差 τ 选定了，这个理论界立刻给出：

$$k \geq \frac{1}{2} \sqrt{\kappa_*} \log \frac{2}{\tau}.$$

- 举例： $\kappa_* = 75$, $\tau = 10^{-2}$ ，公式给出 $k \approx 3-4$ 。

收敛实验设计

2) “一次 Hsym 等价 2 次 AD 调用”“跑满 m 步就做了 m 次 Hsym·v”到底什么意思？

Lanczos 找极值要不要 2m 次 AD？m 是超参数吗？

Lanczos:

- 你在附录 A.8 开头写了：“symmetrized HVP 作为基本计算单元，由 1 次 JVP + 1 次 VJP 组成”

 HILDA_ICLR0。

这就是：对任意向量 v ，我们计算

m 是超级参数

$$H_{\text{sym}}v = \frac{1}{2}(\underbrace{\text{JVP}(v)}_{\text{一次 AD}} + \underbrace{\text{VJP}(v)}_{\text{一次 AD}})$$

r 也是（分摊）

⇒ 一次 $H_{\text{sym}}v$ （一次“HVP”）≈ 2 次 AD 调用。

- Lanczos 的 m 步：**经典 Lanczos 每步都需要一次 $H_{\text{sym}}v$ （再配三对角投影/正交化），跑到 m 步就做了 m 次 $H_{\text{sym}}v$ （≈ 2m 次 AD）。Lanczos 用这 m 次算出一个 m×m 的三对角矩阵 T_m ，对 T_m 求特征值的最大/最小 Ritz 值就近似 $\lambda_{\max}, \lambda_{\min}$ （你在方法部分已解释 Lanczos/Krylov 的原理） HILDA_ICLR0。
- m 是超参数吗？**是的。它控制谱估计的精度 ↔ 成本折中。你在实现策略里也给了建议范围 m=3–5（小常数，够用） HILDA_ICLR0。

1) 我在论文里有没有提 “r”？默认每一步都做 Lanczos 怎么写？

有的。你在附录 A.8 Implementation Strategies 里明确写了“Sparse Eigenvalue Re-estimation：每隔 r 步更新一次极值特征值（推荐 $r=2$ 或 4），从而把 Lanczos 的开销摊到多步上” HILDA_ICLR0。并且同一小节里，你把每步的 HVP 成本写成“(m+k)”（其中 $m=3-5$ 为 Lanczos 步数、 $k=3-6$ 为 CG 迭代），并解释这是结合这些优化策略后的总成本评估 HILDA_ICLR0。

- 如果你现在决定默认每一步都做 Lanczos，那就等价于设 $r=1$ 。写法上很简单：
 - 在实现策略里把 “ $r=2/4$ ” 改成 “ $r=1$ （默认）”；
 - 成本统计从 “摊薄后 m/r ” 还原为 “每步 m ”；
 - 其它表述不变（ m 仍是 3–5 的小常数，见下文）。

1) $\kappa(A_t)$ 是什么？为什么“要保证 $\kappa(A_t) \leq \kappa_*$ ”还需要可视化？

- 你在每个时刻 t 解的线性系统是

$A_t d = g$, 其中 $A_t := H_{\text{sym}} + \lambda_t I$ (H_{sym} 是对称化的 HVP 算子)。

- $\kappa(A_t)$ 是 A_t 的条件数 (谱条件数):

$$\kappa(A_t) = \frac{\lambda_{\max}(A_t)}{\lambda_{\min}(A_t)}.$$

- 你设定了一个目标上界 κ_* (超参数), 并用 Lanczos 得到的极值谱估计 $\hat{\alpha}_t \approx \lambda_{\max}(H_{\text{sym}})$, $\hat{\beta}_t \approx \lambda_{\min}(H_{\text{sym}})$ 去算阻尼:

$$\lambda_t = \max\left(0, \frac{\hat{\alpha}_t - \kappa_* \hat{\beta}_t}{\kappa_* - 1}\right).$$

若 $\hat{\alpha}_t, \hat{\beta}_t$ 等于真实极值, 可直接代入可证

$$\frac{\alpha + \lambda_t}{\beta + \lambda_t} = \kappa_* \quad (\text{或 } \alpha/\beta \leq \kappa_* \text{ 时 } \lambda_t = 0),$$

也就是 $\kappa(A_t)$ 被精确压到 $\leq \kappa_*$ 。

- 但现实里 $\hat{\alpha}_t, \hat{\beta}_t$ 有估计误差, 且若你用了重估周期 $r > 1$ 会跨步复用旧估计; 于是真实的 $\kappa(A_t)$ 可能略高于 κ_* 。

→ 这就是为什么建议可视化一个“预测 vs 观测”:

- 预测: $\hat{\kappa}_t = \frac{\hat{\alpha}_t + \lambda_t}{\hat{\beta}_t + \lambda_t}$ (由当前估计数算);
- 观测: 看 CG 实际收敛所需迭代 **k_obs** 与理论上界

$$k_{\text{pred}} = \left\lceil \frac{1}{2} \sqrt{\hat{\kappa}_t} \log \frac{2}{\tau} \right\rceil$$

的吻合度。若 $\kappa(A_t)$ 真偏大， k_{obs} 会系统性高于 k_{pred} 。

→ 做一张 k_{obs} 对 k_{pred} 的散点图 + “y=x” 参考线；或画 $k_{\text{obs}} - k_{\text{pred}}$ 的分布。这比直接“估 κ 真值”更可行也更有说服力。

2) CG 里的 “k” 是什么？和 κ_* 、 λ_t 、 τ 的关系？

- 这里的 k 指 CG 实际迭代次数（结果量，不是超参数）。
- λ_t 是在 Lanczos 阶段根据 $\hat{\alpha}_t, \hat{\beta}_t, \kappa_*$ 算出来的，在该步是固定的；它决定了 A_t ，从而决定了真实条件数 $\kappa(A_t)$ 。
- τ 是 CG 的残差容差（超参数）：要求 $\|r^{(k)}\| / \|r^{(0)}\| \leq \tau$ 。
- 经典收敛界：

$$\frac{\|r^{(k)}\|}{\|r^{(0)}\|} \leq 2 \left(\frac{\sqrt{\kappa(A_t)} - 1}{\sqrt{\kappa(A_t)} + 1} \right)^k \Rightarrow k \gtrsim \frac{1}{2} \sqrt{\kappa(A_t)} \log \frac{2}{\tau}.$$

所以：

- κ_* ：通过影响 λ_t 来间接决定（上界）收敛速度；
- τ ：你要求多准， k 就要多大；
- k ：在给定 (λ_t, τ) 下的实际迭代次数，由数据/谱决定。

结论： λ_t 固定 $\neq k$ 固定； k 仍随谱和 τ 变化。 κ_* 不是 k ，而是你希望 $\kappa(A_t)$ 不超过的目标值。

3) 超参数到底有几个?

主线就这 四个:

1. m (Lanczos 步数)
2. r (Lanczos 重估周期; $r=1$ 表示每步都估)
3. κ^* (目标条件数上界, 用来算 λ_t)
4. τ (CG 残差容差)

可选/工程开关 (不一定要写成“超参数”):

- **maxit** (CG 保护性上限, 如 6/8 步)
- **warm-start** (用上一步解初始化 CG)
- **re-orth** (Lanczos 是否做选择性重正交, 用于参考强设定)
- **m_ref** (仅用于“近真值”评估的参考 m , 非运行时必需)

4) 你可以怎么画 (很省事又有力)

- 图 A: k_{obs} vs k_{pred} (散点): 点落在对角线附近 $\Rightarrow$ 说明用 (m, r, κ^*) 得到的谱估计足以“预测”CG 收敛。
- 图 B: k_{obs} 直方图 (不同 τ): τ 越小, 分布整体右移 (迭代增多)。
- 图 C: $\hat{\kappa}_t$ 随 t 的曲线 (或箱线图; 分早/中/晚阶段): 验证大多数时刻被控在 $\leq \kappa^*$ 附近; 若用 $r>1$, 看看剧烈阶段是否略冒顶。
- 表 D: 不同 (m, r) 下的 HVP 成本/步 与上面三图的统计: 把“代价—精度 (预测准确度)—稳定性”连起来。

